

ANEXO 8

VALIDACIÓN MULTIVARIADA DE LA CLASIFICACIÓN FUNCIONAL DE LOS POZOS DE MONITOREO

PCA, t-SNE, clustering y evaluación de robustez estadística

Indicador sintético empleado: ISAC (sin inclusión del ICEH)

1. Propósito y alcance

Este anexo documenta y valida la clasificación multivariada de 17 pozos de monitoreo mediante cinco descriptores hidrogeológicos: desviación estándar intra-pozo (σ), rango de variación, pendiente de regresión lineal ordinaria (β OLS), autocorrelación de primer orden (ρ_1) e Índice Sintético de Alerta y Control (ISAC). El ICEH no fue utilizado, de conformidad con la versión definitiva de la metodología de la tesis.

La validación integra: estadística descriptiva, correlación, pruebas de adecuación para PCA, reducción dimensional lineal y no lineal, agrupamiento K-means con cuatro conglomerados, comparación con clustering jerárquico y Gaussian Mixture Models, métricas internas de calidad y estabilidad frente a perturbaciones bootstrap.

Precisión metodológica. PCA y t-SNE no generan por sí mismos la partición; son técnicas de representación. La robustez de los conglomerados se sustenta mediante la concordancia entre algoritmos, la estabilidad de la asignación y la coherencia hidrogeológica de los perfiles.

2. Matriz de características

La matriz definitiva contiene 17 observaciones y cinco variables activas. El porcentaje de registros imputados se conserva como indicador de trazabilidad, pero no se incluye en el espacio de clustering para evitar que la calidad del registro sustituya el comportamiento hidrogeológico.

N.º	Pozo	σ	Rango	β OLS	ρ_1	ISAC	Clúster k=4
1	Sampués – 52-II-C-PZ-01	4.700	15.280	0.980	0.970	0.420	1
2	Finca el Socorro – 44-II-D-PO-02	0.640	3.130	0.075	0.910	0.840	3
3	Ovejas – 44-II-D-PO-14	2.780	8.190	0.380	0.940	0.620	2
4	Los Palmitos – 44-IV-B-PZ-01	3.850	10.420	-0.120	0.950	0.550	2
5	Bremen – 44-IV-C-PZ-01 A	0.620	2.320	0.050	0.880	0.880	3
6	Bremen – 44-IV-C-PZ-01 B	0.790	2.510	0.090	0.900	0.830	3
7	Las Tinas – 44-IV-C-PZ-02 A	5.120	23.370	1.040	0.980	0.210	4
8	Las Tinas – 44-IV-C-PZ-02 B	0.470	1.860	0.070	0.870	0.900	3
9	Arroyo Betulia A – 44-IV-D-PZ-01 A	6.400	29.070	1.420	0.990	0.180	4
10	Arroyo Betulia B – 44-IV-D-PZ-01 B	0.880	3.960	0.450	0.930	0.710	2
11	Sabanas de Cali – 44-IV-D-PZ-02	7.900	25.670	1.610	0.990	0.140	4
12	Finca El Tesoro – 44-IV-D-PZ-04	3.720	20.450	0.820	0.960	0.500	1

13	Basurero Viejo – 52-II-B-PZ-01 A	2.400	7.620	0.490	0.940	0.680	2
14	Corozal – 44-IV-D-PO-14	6.850	24.600	1.390	0.980	0.230	4
15	Corozal – 44-IV-D-PZ-20	1.470	4.690	0.310	0.920	0.740	2
16	Corozal – 44-IV-D-PZ-22	6.300	23.520	1.640	0.990	0.190	4
17	Cantagallo – 52-II-A-PZ-01	3.020	12.130	0.550	0.950	0.580	2

3. Estadística descriptiva

Los descriptores presentan escalas y dispersiones heterogéneas, por lo cual fueron estandarizados mediante puntuaciones z antes del PCA y del clustering. Esta operación impide que las variables de mayor amplitud dominen artificialmente las distancias euclídeas.

Variable	Media	DE	CV (%)	Min.	P25	Mediana	P75	Máx.	Asimetría
Sigma	3.406	2.460	72.229	0.470	0.880	3.020	5.120	7.900	0.377
Rango	12.870	9.643	74.927	1.860	3.960	10.420	23.370	29.070	0.373
Beta_OLS	0.661	0.588	88.857	-0.120	0.090	0.490	1.040	1.640	0.461
Rho1	0.944	0.038	4.052	0.870	0.920	0.950	0.980	0.990	-0.518
ISAC	0.541	0.268	49.517	0.140	0.230	0.580	0.740	0.900	-0.263

4. Dependencia entre variables

La matriz de Pearson evidencia una fuerte estructura común. σ , rango y β OLS aumentan conjuntamente, mientras el ISAC disminuye cuando se incrementan la variabilidad y la tendencia de profundización. Esta colinealidad no invalida el PCA; por el contrario, justifica su uso para sintetizar el eje hidrodinámico dominante.




Figura A8-1. Matriz de correlación de Pearson de los cinco descriptores.

5. Adecuación para el análisis de componentes principales

El índice KMO global fue 0.884, valor considerado alto para una matriz de cinco variables. La prueba de esfericidad de Bartlett fue significativa ($\chi^2 = 140.52$; $p < 0,001$), rechazando la hipótesis de una matriz de correlación identidad. En consecuencia, la reducción mediante PCA es estadísticamente pertinente.

Indicador	Resultado	Interpretación
KMO global	0.884	Adecuación alta
Bartlett χ^2	140.517	Correlación conjunta significativa
Bartlett p	0.000	PCA justificable

6. Resultados del PCA

El primer componente explicó 94.43% de la variabilidad y los dos primeros componentes acumularon 97.32%. La concentración de la varianza en PC1 muestra que los cinco descriptores representan, en gran medida, un gradiente hidrodinámico común que contrapone pozos estables y pozos sometidos a mayor variabilidad, amplitud y pendiente de descenso.

PC	Autovalor	Varianza (%)	Acumulada (%)
1	5.017	94.429	94.429
2	0.154	2.893	97.323
3	0.081	1.528	98.851
4	0.047	0.889	99.740
5	0.014	0.260	100.000




Figura A8-2. Scree plot y varianza explicada acumulada.




Figura A8-3. Cargas de las variables sobre los dos primeros componentes.




Figura A8-4. Distribución de los pozos en el plano PC1-PC2. La numeración corresponde a la Tabla A8-1.

7. Representación t-SNE

La proyección t-SNE fue calculada con perplejidad 5 y semilla aleatoria fija. El índice de trustworthiness fue 0.991, lo que indica una conservación excelente de las vecindades locales. Por tratarse de una técnica no lineal, las distancias globales y la orientación de los ejes no deben interpretarse hidrogeológicamente; su utilidad se concentra en comprobar la continuidad local de los grupos.




Figura A8-5. Representación t-SNE de los pozos, coloreada según la partición K-means k=4.

8. Selección del número de conglomerados

Se evaluaron soluciones entre $k=2$ y $k=6$. El mayor índice Silhouette se obtuvo para $k=2$. Por tanto, la solución de cuatro conglomerados no debe presentarse como el óptimo geométrico único. Su adopción responde a una decisión teóricamente dirigida: distinguir cuatro niveles funcionales con significado hidrogeológico, manteniendo una separación interna aceptable y una elevada reproducibilidad entre algoritmos.

k	Silhouette	Davies-Bouldin	Calinski-Harabasz	Inercia
2	0.607	0.503	48.199	20.174
3	0.512	0.595	51.784	10.122
4	0.474	0.564	53.376	6.383
5	0.423	0.618	53.420	4.520
6	0.459	0.477	52.447	3.422




Figura A8-6. Índice Silhouette para las soluciones k=2 a k=6.

9. Validación de la partición de cuatro conglomerados

La partición K-means coincidió plenamente con el agrupamiento jerárquico de Ward ($ARI = 1.000$; $NMI = 1.000$). La comparación con un modelo de mezclas gaussianas produjo una concordancia moderada-alta ($ARI = 0.541$; $NMI = 0.735$), lo que muestra que parte de la estructura depende del supuesto geométrico del algoritmo, aunque los grupos extremos permanecen claramente diferenciados.

La estabilidad se evaluó mediante 500 perturbaciones aleatorias equivalentes al 5% de una desviación estándar en el espacio normalizado. El ARI medio fue 0.848, la mediana 0.875 y el intervalo percentil del 95% [0.541, 1.000]. Estos resultados indican estabilidad alta, aunque no absoluta, especialmente en los pozos ubicados en zonas de transición.




Figura A8-7. Dendrograma obtenido mediante el método de Ward.




Figura A8-8. Distribución de la estabilidad ARI en 500 perturbaciones bootstrap.

10. Perfiles de las cuatro tipologías dinámicas

Clúster	n	σ media	Rango medio	β OLS media	ρ_1 media	ISAC medio
---------	---	----------------	-------------	-------------------	----------------	------------

1	2	4.210	17.865	0.900	0.965	0.460
2	6	2.400	7.835	0.343	0.938	0.647
3	4	0.630	2.455	0.071	0.890	0.862
4	5	6.514	25.246	1.420	0.986	0.190




Figura A8-9. Perfiles estandarizados de los cuatro conglomerados.

10.1 Clúster 1: Transicional de alta amplitud

Agrupar dos pozos con variabilidad y rango altos, pendiente positiva relevante e ISAC intermedio. Representa sistemas con descenso sostenido y amplitud considerable, pero sin alcanzar la severidad conjunta del grupo crítico.

Pozos: Sampedra – 52-II-C-PZ-01; Finca El Tesoro – 44-IV-D-PZ-04

10.2 Clúster 2: Transicional moderado

Reúne pozos de variabilidad y tendencia moderadas, con ISAC medio-alto. Corresponde a una condición transicional que requiere seguimiento, pues combina persistencia temporal con señales de presión no extrema.

Pozos: Ovejas – 44-II-D-PO-14; Los Palmitos – 44-IV-B-PZ-01; Arroyo Betulia B – 44-IV-D-PZ-01 B; Basurero Viejo – 52-II-B-PZ-01 A; Corozal – 44-IV-D-PZ-20; Cantagallo – 52-II-A-PZ-01

10.3 Clúster 3: Estable

Presenta los menores valores de σ , rango y pendiente, junto con el ISAC más alto. Constituye la tipología de mayor estabilidad relativa y menor presión hidrodinámica observada.

Pozos: Finca el Socorro – 44-II-D-PO-02; Bremen – 44-IV-C-PZ-01 A; Bremen – 44-IV-C-PZ-01 B; Las Tinas – 44-IV-C-PZ-02 B

10.4 Clúster 4: Dinámico o crítico

Concentra los valores más altos de variabilidad, rango, pendiente y persistencia, junto con los ISAC más bajos. Representa los pozos de mayor vulnerabilidad y presión extractiva relativa.

Pozos: Las Tinas – 44-IV-C-PZ-02 A; Arroyo Betulia A – 44-IV-D-PZ-01 A; Sabanas de Cali – 44-IV-D-PZ-02; Corozal – 44-IV-D-PO-14; Corozal – 44-IV-D-PZ-22

11. Coherencia entre PCA, t-SNE y clustering

La convergencia metodológica debe entenderse en tres niveles. Primero, PC1 sintetiza casi toda la variabilidad de los descriptores y ordena los pozos a lo largo de un gradiente de estabilidad-presión. Segundo, t-SNE conserva las vecindades locales con alta fidelidad. Tercero, K-means y Ward reproducen exactamente la misma partición de cuatro grupos. Esta convergencia no significa que PCA y t-SNE produzcan clústeres idénticos, sino que las representaciones lineal y no lineal son coherentes con una estructura de proximidad que también es recuperada por algoritmos de agrupamiento independientes.

12. Limitaciones

- El tamaño muestral es reducido ($n=17$), por lo cual las métricas internas deben interpretarse junto con la plausibilidad hidrogeológica.
- Las variables presentan alta colinealidad. El PCA la sintetiza, pero también muestra que varias métricas expresan una misma dimensión latente.
- El valor $k=4$ no es el máximo por Silhouette. Su justificación es teórica y funcional, no exclusivamente geométrica.
- t-SNE es sensible a hiperparámetros y semilla; por ello se fijó `random_state` y se evaluó `trustworthiness`.
- La clasificación describe similitud estadística y no demuestra causalidad. Las tipologías deben contrastarse con extracción, recarga, geología y localización espacial.

13. Conclusiones

La matriz de descriptores es adecuada para reducción dimensional y presenta una dimensión dominante que integra variabilidad, amplitud, tendencia, persistencia e ISAC.

La clasificación de cuatro tipologías es estable y reproducible entre K-means y Ward, pero debe declararse como una solución teóricamente dirigida, dado que el máximo Silhouette corresponde a $k=2$.

Los grupos extremos —estable y dinámico/crítico— muestran perfiles claramente separados; la mayor incertidumbre se concentra en las tipologías transicionales.

El Anexo 8 respalda la clasificación funcional sin recurrir al ICEH y mantiene consistencia con la versión definitiva de la tesis basada en ISAC.